

의료 영상 기반 준지도 학습 이상 탐지 모델

왕승재, 홍현기

Semi-supervised anomaly detection for medical images based on Patchcore

Sheng Tsai Wang, Hyun Ki Hong

요 약

최근 임상 및 병리 분야에서는 데이터 및 어노테이션 확보, 클래스 불균형, 주관적인 소견 차이 문제를 해결하고자 병리 데이터를 디지털화 시켜 공유 및 분석하는 디지털 병리학 분야로의 연구가 진행중이다. 본 논문에서는 이러한 특성의 병리 데이터에 적합한 소량의 이상 데이터를 학습하여 이상 소견을 분류하고, 유사한 특성을 가지는 데이터에 대해 검증을 수행한다. 컴퓨터 비전에서 사용되는 BackBone 모델을 이용한 전이학습을 이용하여 소량의 이상 데이터에 대해 분별력을 가지는 특징 추출을 수행하고 이를 분류하는 이상 탐지 모델을 제안한다. 제안한 모델로 확보한 데이터에 대한 검증과 유사한 Br35H 데이터셋과 SARS-COV-2_CT-Scan 데이터셋에 대한 실증을 수행하여 각 96%와 90%의 정확도를 달성하였다.

Abstract

Recently, in the field of clinical and pathology, research is underway into the field of digital pathology that digitizes, shares, and analyzes pathology data to secure data and annotations, solve class imbalances, and subjective differences. In this paper, we learn a small amount of anomaly data suitable for pathological data of these characteristics to classify anomaly findings, and perform verification on data with similar characteristics. We propose an anomaly detection model that performs discernible feature extraction on small amounts of anomaly data using transition learning using the BackBone model used in computer vision and classifies them. We achieve 99% accuracy by performing demonstrations on MHIIST datasets similar to verification on the data obtained by the proposed model.

Key words

deep learning, anomaly detection, convolutional neural network

1. 서 론

디지털 병리학(Digital Pathology)은 디지털 스캐너를 사용하여 병리 슬라이드를 디지털 영상으로 변환하여 보관 및 분석하는 연구방법으로 최근 정보 공유의 관점에서 시도되고 있다. 병리 분석 데이터를 디지털화 함에 따라 인공지능 모델을 사용하여 장기

(tissue) 분류, 이상 소견 영역 표시 등을 통한 병리 지원 모델의 연구가 가능해지고 있다. 또한, CT 데이터 등은 배울 규격에 따른 다양한 해상도를 지원하는 데이터로 컴퓨터 비전 기법과 인공지능 기법의 효율적인 접근 및 다양한 특성의 데이터 확보에 유리한 데이터 형태이다. 본 연구에서는 의료 영상 데이터를 기반으로 이상 소견 영역을 분류하는 모델을


제한한다.

II. 관련 연구

병리 및 조직 데이터를 이용한 인공지능 연구는 이상 데이터 확보, 픽셀 단위의 어노테이션 부재, 병리학자의 주관적인 소견, 다양한 이상 소견 및 소견별 이상 조직 판단에 대한 역치 차이, 이상 데이터에 대한 이상 소견 영역 또는 소견 빈도에 대한 임계치 부재 등의 문제점과 높은 수준의 정확도를 요구하는 분야이다. 때문에, 인공지능 모델의 판단을 보조 또는 1차적 필터링으로서 사용하는 방향의 제품 및 연구 결과들이 일반적으로 수행된다.

컴퓨터 비전 분야에서 인공지능 모델은 ImageNet 데이터를 기반으로 사전학습된 ResNet[1], EfficientNet[2], Inception[3], VGGNet[4] 등의 Backbone 모델을 특징 추출, 차원 축소 또는 전이 학습을 이용하여 연구된다. Backbone 모델을 거처 나온 결과는 ResNet 기준 1000개의 특징을 가진 데이터로 변화되고 이에 대해 추가적인 데이터 전처리 및 분류, 군집등의 모델을 추가하는 방식으로 진행된다.

III. 설계 방법



(그림1) 제안한 알고리즘 Flow Chart

본 연구에서는 ImageNet 사전학습 모델을 기반으로 전이학습을 통한 의료 영상에 대한 정상/비정상 분류를 위한 이상 탐지 모델 및 분류 모델을 제안한다. 학습데이터는 정상과 비정상 CT 영상으로 나누어진 SARS-COV-2 Ct-Scan Dataset[5]과 Br35H :: Brain Tumor Detection 2020 Dataset[6]을 사용한다.

BackBone모델을 사용한 특징추출로 각 영상 데이터는 1000개의 특징을 가지는 데이터로 변환하였고, 이를 Standard Scaler를 이용한 정규화 및 Priciple

Component Analysis(PCA)를 이용한 차원축소를 수행한 후, 분류 및 이상탐지 모델을 통해 이상 분류를 수행한다.

이상 탐지 및 분류 모델은 특징 분포 및 거리를 이용하는 K-Nearest Neighbor(KNN) 분류 모델을 사용했다.

IV. 결 과

공개 데이터셋인 SARS-COV2 Ct-Scan Datsset과 Br35H Dataset에 대해 이상 탐지 결과를 분석한다.

Resnet50	ROC_AUC	Total run time / Predict run time
Br35H	0.96	955s / 42s
SARS-COV-2	0.90	1234s / 40s

표 1 Resnet50 - KNN 모델의 Validation

Resnet101	ROC_AUC	Total run time / Predict run time
Br35H	0.91	1655s / 67s
SARS-COV-2	0.90	1288s / 57s

표 2 Resnet101 - KNN 모델의 Validation

Resnet101	ROC_AUC	Total run time / Predict run time
Br35H	0.99	1359s / 50s
SARS-COV-2	0.89	1115s / 41s

표 3 Wide-Resnet50 - KNN 모델의 Validation

SARS-COV-2 Ct-Scan Dataset은 정상 1500개, 비정상 1500개로 구성되어 있으며, Backbone model 학습시에는 정상 데이터 1126개로만 학습을 진행한 후, 정상 374개와 비정상 1500개로 검증을 실시했다. Br35H Dataset의 경우 정상 1229개와 비정상 1252개로 구성되어 있으며, Backbone model 학습시에는 정상 데이터 898개로만 학습을 진행한 후, 정상 331개와 비정상 1252개로 검증을 실시했다.

V. 부 록

[5]SARS-COV-2 Ct-Scan Dataset:

<https://www.kaggle.com/datasets/plameneduardo/sarscov2-ctscan-dataset?select=non-COVID>

[6]Br35H :: Brain Tumor Detection 2020 Dataset:
<https://www.kaggle.com/datasets/ahmedhamada0/brain-tumor-detection?select=yes>

https://github.com/essential2189/CAU_Computer_Vision/tree/main/project2/

참 고 문 헌

- [1] He, Kaiming, et al. "Deep residual learning for image recognition." Proceedings of the IEEE conference on computer vision and pattern recognition. 2016.
- [2] Tan, Mingxing, and Quoc Le. "Efficientnet: Rethinking model scaling for convolutional neural networks." International conference on machine learning. PMLR, 2019.]
- [3] Szegedy, Christian, et al. "Rethinking the inception architecture for computer vision." Proceedings of the IEEE conference on computer vision and pattern recognition. 2016.
- [4] Simonyan, Karen, and Andrew Zisserman. "Very deep convolutional networks for large-scale image recognition." arXiv preprint arXiv:1409.1556 (2014).